

DayOne

Une sage-femme, un téléphone et une IA

Un agent hors-ligne qui transforme les photos du registre maternel papier en dossier structuré, vérifié et longitudinal.

Le problème

Le registre papier reste, la donnée ne circule pas

- Le suivi maternel vit dans un registre papier : 8 types de pages, écriture manuscrite, cases cochées.
- Le réseau peut manquer pendant des jours : rien ne doit dépendre d'Internet ni être perdu.
- Les données sont sensibles : nom, mari, CIN, téléphone, adresse ne doivent jamais sortir.
- Une IA qui invente une valeur clinique est pire qu'une IA qui pose une question.

Notre réponse

La sage-femme garde son registre. Le téléphone le lit, ne montre que ce dont il doute, chiffre tout jusqu'au retour du réseau, et relie chaque visite à la bonne patiente par son code.

Architecture

Téléphone hors-ligne + boîtier local dans la structure de santé

Téléphone — PWA hors-ligne

- Capture + contrôle qualité sur l'appareil (flou, sombre, reflet)
- IndexedDB chiffrée AES-GCM, clé dérivée du PIN
- Cycle de vie + journal d'événements, reprise après redémarrage
- Révision conversationnelle type WhatsApp (FR / EN)
- Liaison patiente : la sage-femme décide
- File d'envoi, synchronisation idempotente

photos



questions

Boîtier edge — Wi-Fi local

- /process : recalage de la page, masquage des identifiants, lecture de chaque champ
- Statuts, confiances calibrées, extraits d'image comme preuve
- Règles de cohérence du carnet à la clôture
- Registre patientes : identifiants aléatoires + code + faits
- Stockage central chiffré, tableau de bord anonymisé
- Seuls les téléphones appairés appellent l'API

L'IA tourne dans la structure : aucune donnée réelle chez un tiers, pages traitées même sans Internet.

Pipeline d'extraction et choix de conception

Partir du schéma du formulaire, pas d'un OCR générique



- 8 gabarits fixes : homographie ECC sur une carte d'encre insensible aux ombres (erreur médiane 1,6 px net, 3,5 px photo téléphone).
- Petit modèle spécialisé : CRNN de 6,7 M de paramètres, ~600 k extraits synthétiques, 69 polices manuscrites, FR / EN / AR.
- Meilleur qu'un modèle généraliste : 0,84 contre 0,65 pour un VLM local 3 B sur les mêmes extraits, 100× plus rapide.
- Contraindre la réponse, pas l'œil : re-notation CTC par grammaire et vocabulaire (dates, TA, unités, régions du Maroc).
- Le carnet se vérifie : DPA = DDR + 280 j, rendez-vous = visite + 28 j ; tout changement est montré à la sage-femme.

Incertitude : ne jamais cacher le doute

Six statuts par champ, une confiance qui veut dire quelque chose

Statut	Quand
CONNU	confiance calibrée $\geq 0,95$ et format / plage valides
À RÉVISER	lu mais douteux (0,35–0,95), règle, photo médiocre
ILLISIBLE	encre présente, illisible ($< 0,35$, ratures)
INCONNU	la sage-femme a écrit « ? », « inconnu », « NSP »
NON_FOURNI	case vide, tiret, aucune case cochée
NON_APPLICABLE	vide et exclu par la logique du formulaire

Mesuré ($\tau = 0,95$)

- Erreurs parmi les textes
CONNU : 0,26 % (net), 0,85 % (photo téléphone)
- Valeurs raturées affichées
CONNU : 0 / 121
- Autre modèle de registre :
PAGE_NON_RECONNUE, 0 champ CONNU
- Blanc lu avec confiance $< 0,9$
: demandé, pas déclaré vide

- Chaque question montre l'extrait d'image ; 8 questions de suite au plus, le doute restant reste enregistré.
- Page non recalée : aucun champ CONNU, aucun extrait ne quitte le boîtier, reprise photo ou saisie manuelle.

Confidentialité et sécurité

Les identifiants ne sont jamais lus, jamais stockés

Masquer avant de lire

- Nom, mari, CIN, téléphone, adresse masqués avant toute lecture
- Masques élargis si le recalage est faible
- Image conservée = photo avec zones peintes ; photo brute supprimée
- 0 fuite d'identifiant sur tous les essais

Identifier sans nommer

- Patiente = code aléatoire du registre + faits non identifiants (DDR, date prévue)
- Identifiants internes : UUID aléatoires
- Jamais de création si une correspondance est plausible
- « Je ne sais pas » : rien n'est lié ni créé

Chiffrer et contrôler

- Téléphone : AES-GCM, PBKDF2 200 k depuis le PIN
- Boîtier : AES-GCM, scrypt, pas de clé par défaut
- Appairage : code à 6 chiffres, jeton 192 bits, HTTPS
- Accès aux images par rôle, chaque accès journalisé

Aucune donnée patiente dans le cache du navigateur : seul le squelette de l'application est mis en cache.

Résultats mesurés

80 pages spécimen (10 patientes × 8 types), jamais vues à l'entraînement, pipeline complet

Qualité de la photo	Champs remplis	Cases cochées	Blancs corrects	Erreurs CONNU	Questions / page
Rendu net (sév. 0)	0,961	1,000	1,000	0,26 %	3,8
Photo légère (sév. 1)	0,942	0,9995	1,000	0,27 %	4,3
Photo téléphone (sév. 2)	0,760	0,992	0,999	0,85 %	11,8
Photo médiocre (sév. 3)	0,634	0,983	0,984	2,3 %	19,2
Test de stress (sév. 4)	0,473	0,922	0,990	1,9 %	25,6

- Avec le contrôle qualité du téléphone (photos acceptées) : 0,816 à sév. 2 (46 sur 80), 0,799 à sév. 3 (28 sur 80).
- Écriture jamais vue à l'entraînement : 0,939 (net) et 0,718 (photo téléphone) — le chiffre à attendre sur de nouvelles mains.
- Langues, pages synthétiques, net : FR 0,969 · EN 0,962 · AR 0,954.
- Produit : répétition de bout en bout 11 / 11 vérifications, 46 tests pytest, 3 dossiers synchronisés exactement une fois.

Limites connues et prochaines étapes

Ce que nous déclarons, et ce qui vient ensuite

Limites déclarées

- Images fournies = rendus nets de pages synthétiques ; les dégradations sont simulées par nous
- Les 5 vraies photos sont d'un autre modèle de registre : rejetées, pas lues
- Réglé sur le jeu de test : règles R1 / H1, seuil de flou, seuils de verdict de page
- Arabe et anglais mesurés sur pages synthétiques uniquement
- Texte libre long = point faible ; saisie manuelle sans le tableau de 280 cellules

Prochaines étapes

- Une journée de collecte de photos du vrai carnet, sans aucune donnée patiente
- Mesurer l'arabe et l'anglais sur de vraies pages
- Réconciliation des dossiers validés : mesurée en simulation seulement (0,866 → 0,945)
- Adaptateur WhatsApp Cloud API : existe, attend un numéro de test Meta
- Déploiement réel : désactiver l'amorçage de démonstration /admin/seed